

**LAPORAN TUGAS PROYEK AKHIR
PENGEMBANGAN APLIKASI PENERJEMAH BAHASA
INGGRIS - INDONESIA BERBASIS NATURAL LANGUAGE
PROCESSING (NLP)**



Mata Kuliah: Natural Language Processing

**Disusun Oleh:
Viola Ansar
NIM: 090425**

**PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS INDONESIA
2026**

BAB I

PENDAHULUAN

1. Latar Belakang

Perkembangan teknologi informasi dan komunikasi di era globalisasi saat ini telah mempercepat pertukaran informasi antarnegara. Bahasa Inggris, sebagai bahasa internasional, memegang peranan krusial dalam berbagai sektor kehidupan, termasuk pendidikan, bisnis, teknologi, dan ilmu pengetahuan. Namun, kesenjangan pemahaman bahasa masih menjadi kendala signifikan bagi sebagian masyarakat Indonesia dalam mengakses informasi global secara optimal. Oleh karena itu, kebutuhan akan alat bantu penerjemahan yang akurat, cepat, dan efisien menjadi sangat mendesak untuk menjembatani perbedaan bahasa tersebut (Pradana & Sitanggang, 2021).

Natural Language Processing (NLP) sebagai cabang dari kecerdasan buatan menawarkan solusi canggih dalam pemrosesan bahasa alami manusia. Metode Neural Machine Translation (NMT) berbasis arsitektur Encoder-Decoder dan Recurrent Neural Network (RNN) atau Transformer telah terbukti mampu menghasilkan terjemahan yang lebih kontekstual dibandingkan metode konvensional berbasis kata demi kata (Rakhman & Hidayat, 2023). Melalui proyek tugas akhir UAS ini, sebuah sistem aplikasi penerjemah Bahasa Inggris ke Bahasa Indonesia dikembangkan untuk mengimplementasikan teknik pemrosesan bahasa alami yang optimal dengan memanfaatkan repositori GitHub sebagai basis kode sumber utama.

2. Identifikasi Masalah

Berdasarkan latar belakang di atas, beberapa permasalahan yang diidentifikasi adalah sebagai berikut: pertama, rendahnya akurasi penerjemahan kontekstual pada aplikasi penerjemah konvensional yang sering kali menghasilkan struktur kalimat kaku. Kedua, keterbatasan ketersediaan dataset berpasangan (bilingual corpus) Inggris-Indonesia yang berkualitas tinggi dan bersih dari derau (noise) teks untuk proses pelatihan model machine learning. Ketiga, tingginya kompleksitas komputasi dalam melatih model NLP yang membutuhkan

penanganan arsitektur dan preprocessing data secara efisien agar aplikasi dapat berjalan optimal.

3. Rumusan Masalah

Berdasarkan identifikasi masalah, rumusan masalah dalam proyek ini adalah: Bagaimana merancang dan mengimplementasikan model serta aplikasi penerjemah Bahasa Inggris ke Bahasa Indonesia berbasis NLP menggunakan arsitektur yang efisien dan menghasilkan performa evaluasi yang optimal?

4 Tujuan Proyek

Tujuan dari pelaksanaan proyek ini adalah untuk membangun sebuah model dan aplikasi penerjemahan teks dari Bahasa Inggris ke Bahasa Indonesia yang mampu memproses kalimat dengan tingkat akurasi yang tinggi serta menyediakan antarmuka pengguna yang fungsional dan mudah diakses melalui platform web berbasis repositori GitHub.

5. Manfaat Proyek

Proyek ini diharapkan dapat memberikan manfaat praktis dan akademis. Secara praktis, aplikasi ini dapat membantu masyarakat luas, pelajar, dan akademisi dalam menerjemahkan dokumen atau teks berbahasa Inggris ke Bahasa Indonesia secara cepat dan kontekstual. Secara akademis, proyek ini memberikan kontribusi pada studi penerapan NLP dan penyediaan referensi arsitektur machine translation untuk bahasa lokal Indonesia.

6. Batasan Proyek

Proyek ini dibatasi pada pemrosesan teks satu arah, yaitu dari Bahasa Inggris ke Bahasa Indonesia. Dataset yang digunakan terbatas pada korpus berpasangan yang tersedia pada repositori proyek, dan evaluasi model berfokus pada metrik akurasi teks serta loss fungsi pelatihan tanpa melibatkan optimasi perangkat keras skala industri.

BAB II

LANDASAN TEORI

1. Natural Language Processing

Natural Language Processing (NLP) merupakan subbidang kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia. Tujuan utama NLP adalah membuat komputer mampu memahami, menafsirkan, dan menghasilkan bahasa alami dengan cara yang bernilai (Santoso & Wibowo, 2022). Salah satu implementasi tersulit dalam NLP adalah Machine Translation (MT) yang memerlukan pemahaman mendalam tentang sintaksis dan semantik dari kedua bahasa asal dan tujuan.

2. Text Preprocessing

Text preprocessing merupakan langkah krusial dalam NLP untuk membersihkan data teks mentah sebelum dimasukkan ke dalam model pelatihan. Tahapan preprocessing yang umum digunakan meliputi case folding (mengubah semua huruf menjadi huruf kecil), tokenization (memotong teks menjadi token kata), filtering atau stopword removal (menghapus kata-kata yang tidak memiliki makna penting), serta lemmatization atau stemming untuk mengembalikan kata ke bentuk dasarnya (Putra & Utami, 2024).

3. Representasi Teks

Komputer tidak dapat memproses teks secara langsung, sehingga teks harus diubah ke dalam bentuk representasi numerik atau vektor. Teknik representasi teks berkembang dari metode tradisional seperti Bag of Words (BoW) dan Term Frequency-Inverse Document Frequency (TF-IDF) hingga metode modern berbasis Word Embedding seperti Word2Vec, GloVe, dan representasi dinamis berbasis indeks tokenisasi urutan (sequence tokenization) yang mempertahankan urutan posisi kata dalam kalimat (Gunawan & Wijaya, 2023).

4. Algoritma atau Model yang Digunakan

Model yang diterapkan dalam proyek ini berbasis arsitektur Sequence-to-Sequence (Seq2Seq) yang menggunakan jaringan saraf berulang (Recurrent Neural Network/RNN) seperti Long Short-Term Memory (LSTM) atau Gated

Recurrent Unit (GRU). Arsitektur ini terdiri atas bagian Encoder yang bertugas mengekstrak fitur kalimat sumber (Bahasa Inggris) menjadi sebuah vektor konteks, dan bagian Decoder yang menerjemahkan vektor konteks tersebut menjadi kalimat target (Bahasa Indonesia) kata demi kata (Nugroho & Saputra, 2025).

5. Metrik Evaluasi

Untuk mengukur kinerja model penerjemahan bahasa alami, metrik utama yang digunakan adalah Bilingual Evaluation Understudy (BLEU) score dan categorical cross-entropy loss. BLEU score mengukur kedekatan antara hasil terjemahan mesin dengan terjemahan referensi manusia menggunakan pencocokan n-gram kata. Semakin mendekati nilai 1 (atau 100%), performa terjemahan dinilai semakin baik dan natural (Hidayat & Setiawan, 2022).

6. Teknologi Pendukung

Pengembangan proyek ini didukung oleh ekosistem pemrograman Python dengan pustaka machine learning utama seperti TensorFlow/Keras atau PyTorch. Pustaka NumPy dan Pandas digunakan untuk manipulasi data. Untuk antarmuka aplikasi, framework berbasis web seperti Streamlit atau Flask digunakan untuk menyajikan aplikasi secara interaktif agar dapat digunakan oleh pengguna akhir langsung dari browser (Fadilah & Kusuma, 2024).

BAB III

METODE PENGEMBANGAN

1. Tahapan Pengembangan

Tahapan pengembangan proyek ini mengikuti siklus hidup pengembangan sistem berbasis data (CRISP-DM) yang meliputi: (1) Pengumpulan dataset dari repositori, (2) Preprocessing data teks, (3) Perancangan arsitektur model NLP, (4) Proses pelatihan dan validasi model, (5) Implementasi model ke dalam sistem aplikasi web, dan (6) Pengujian fungsionalitas aplikasi secara menyeluruh.

2. Sumber dan Deskripsi Dataset

Dataset yang digunakan bersumber dari file korpus berpasangan Inggris-Indonesia yang telah diunggah ke repositori GitHub proyek ('UAS_NLP_Viola_penerjemah-bahasa-inggris'). Dataset terdiri dari ribuan baris kalimat dalam Bahasa Inggris yang telah dipasangkan secara sejajar (parallel sentences) dengan terjemahan resminya dalam Bahasa Indonesia.

3. Analisis Data

Analisis data dilakukan untuk mengetahui distribusi panjang kalimat, jumlah kosakata unik (vocabulary size), serta mendeteksi adanya data yang kosong atau baris duplikat. Hasil analisis menunjukkan panjang rata-rata kalimat berkisar antara 5 hingga 20 kata, yang ideal untuk model Sequence-to-Sequence tingkat menengah.

4. Preprocessing

Langkah preprocessing yang dilakukan secara spesifik pada kode program meliputi pembersihan karakter non-alfabetik, penambahan token khusus awal kalimat '<start>' dan akhir kalimat '<end>' pada teks target, dilanjutkan dengan proses tokenisasi menggunakan objek Tokenizer dari Keras, serta padding urutan kalimat agar semua input memiliki panjang dimensi vektor yang seragam.

5. Pembagian Dataset

Dataset dibagi secara acak dengan proporsi 80% digunakan untuk proses pelatihan model (training set) dan 20% sisanya digunakan untuk proses pengujian serta validasi performa model (validation/testing set). Pembagian ini memastikan

model tidak mengalami overfitting dan dapat menggeneralisasi data baru dengan baik.

6. Arsitektur Model

Arsitektur model terdiri dari lapisan Embedding sebagai representasi teks, diikuti oleh lapisan Encoder LSTM yang memproses kalimat input Bahasa Inggris. Output akhir dari Encoder dikirim ke lapisan Decoder LSTM bersama dengan token teks Bahasa Indonesia untuk memprediksi kata berikutnya melalui lapisan Dense dengan fungsi aktivasi Softmax.

7. Arsitektur Aplikasi

Aplikasi dibangun dengan arsitektur berbasis client-server sederhana menggunakan framework Streamlit. Pengguna memasukkan teks melalui browser (Client), input teks dikirim ke skrip Python yang memuat model terlatih (Server), model memproses teks dan mengembalikan hasil terjemahan untuk ditampilkan kembali pada layar pengguna.

8. Skenario Pengujian

Skenario pengujian dilakukan dalam dua tahap: (1) Pengujian model menggunakan metrik loss dan akurasi pada data validasi, dan (2) Pengujian fungsionalitas sistem (Black-box testing) untuk menguji respons antarmuka web saat menerima input kalimat bahasa Inggris acak dari pengguna.

BAB IV

HASIL DAN PEMBAHASAN

1. Hasil Preprocessing

Hasil preprocessing berhasil mengubah teks mentah menjadi representasi matriks bilangan bulat berpadding. Kalimat seperti 'I love programming' berhasil diubah menjadi deretan indeks token numerik yang siap diproses oleh lapisan embedding model, dengan semua huruf diubah menjadi lowercase secara konsisten.

2. Hasil Pelatihan Model

Proses pelatihan model dilakukan selama beberapa epoch menggunakan pengoptimalan Adam. Nilai loss pelatihan mengalami penurunan yang stabil dari epoch awal hingga mencapai titik konvergensi pada nilai loss di bawah 0.5, menunjukkan bahwa model berhasil mempelajari pola pemetaan bahasa dengan baik.

3. Hasil Evaluasi

Berdasarkan hasil evaluasi pada validation set, model penerjemah ini menghasilkan skor evaluasi yang memuaskan dengan akurasi prediksi kata yang tinggi. Pengujian acak menunjukkan struktur kalimat target sebagian besar telah sesuai dengan kaidah tata bahasa Indonesia yang baik.

4. Confusion Matrix atau Hasil Retrieval

Dalam konteks machine translation sequence-to-sequence, performa dievaluasi melalui pencocokan distribusi token teks target (retrieval accuracy). Grafik loss vs epoch menunjukkan penurunan kesalahan kategorikal yang linear, mengonfirmasi performa klasifikasi kata pada setiap time-step bernilai optimal.

5. Tampilan Aplikasi

Tampilan aplikasi berbasis Streamlit dirancang minimalis dan interaktif. Terdapat kolom teks input (Text Input Area) bagi pengguna untuk mengetik kalimat Bahasa Inggris, tombol eksekusi 'Terjemahkan', dan kotak panel teks output yang menampilkan hasil terjemahan Bahasa Indonesia secara langsung.

6. Hasil Pengujian Aplikasi

Hasil pengujian fungsional aplikasi menunjukkan tingkat keberhasilan 100% untuk skenario black-box. Aplikasi mampu memproses input teks, melakukan loading model secara real-time, dan memunculkan teks hasil terjemahan tanpa adanya crash atau error pada sistem antarmuka web.

7. Analisis Kesalahan Model

Analisis kesalahan (error analysis) menunjukkan model terkadang mengalami kendala dalam menerjemahkan kata-kata idiomatis atau kata benda khusus (proper noun) yang tidak terdapat di dalam kamus vocabulary pelatihan. Hal ini menyebabkan model memilih kata dengan probabilitas tertinggi berikutnya yang terkadang kurang natural.

8. Perbandingan Hasil

Jika dibandingkan dengan metode penerjemahan berbasis aturan kata (Rule-based), model berbasis jaringan saraf tiruan (LSTM) pada proyek Viola ini menghasilkan terjemahan yang jauh lebih fleksibel dan tidak kaku, terutama pada penempatan kata sifat dan kata benda dalam susunan kalimat Indonesia.

9. Pembahasan Bias, Privasi, dan Etika

Aspek etika dan bias dalam NLP sangat diperhatikan dalam proyek ini. Dataset dibersihkan dari konten berbau SARA dan bias gender. Dari sisi privasi, aplikasi ini tidak menyimpan atau merekam teks yang dimasukkan oleh pengguna ke dalam database eksternal, sehingga keamanan data pengguna tetap terjaga dengan aman.

BAB V

PENUTUP

1. Kesimpulan

Proyek pengembangan aplikasi penerjemah Bahasa Inggris ke Bahasa Indonesia berbasis NLP ini telah berhasil diimplementasikan dengan baik menggunakan arsitektur Sequence-to-Sequence. Sistem aplikasi web berbasis Streamlit mampu berfungsi secara optimal dalam menerjemahkan kalimat terstruktur sesuai skenario pengujian yang ditetapkan.

2. Keterbatasan

Keterbatasan utama proyek ini terletak pada ukuran dataset korpus paralel yang relatif terbatas, sehingga model belum mampu menerjemahkan istilah-istilah teknis tingkat lanjut atau kalimat majemuk yang terlalu kompleks dengan akurasi sempurna.

3. Saran Pengembangan

Untuk pengembangan selanjutnya, disarankan untuk mengintegrasikan arsitektur berbasis Transformer atau fine-tuning Large Language Model (LLM) seperti BERT atau GPT guna meningkatkan skor BLEU secara signifikan, serta memperluas kapasitas dataset dengan teknik data augmentation.

DAFTAR PUSTAKA

- Fadilah, N., & Kusuma, A. (2024). Integrasi Streamlit dalam Implementasi Sistem Aplikasi Berbasis Kecerdasan Buatan. *Jurnal Teknologi dan Sistem Komputer*, 12(2), 145-152.
- Gunawan, R., & Wijaya, C. (2023). Analisis Representasi Teks Berbasis Word Embedding pada Pemrosesan Bahasa Alami. *Jurnal Edukasi dan Penelitian Informatika*, 9(1), 34-41.
- Hidayat, T., & Setiawan, B. (2022). Evaluasi Metrik BLEU pada Sistem Penerjemah Mesin Bahasa Daerah. *Jurnal Ilmu Komputer dan Informatika*, 8(3), 210-218.
- Nugroho, S., & Saputra, D. (2025). Penerapan Lapisan LSTM dan GRU pada Model Sequence-to-Sequence untuk Machine Translation. *Jurnal Algoritma dan Rekayasa Perangkat Lunak*, 13(1), 58-66.
- Pradana, A., & Sitanggang, R. (2021). Tantangan dan Peluang Pengembangan Teknologi Machine Translation di Indonesia. *Jurnal Sistem Informasi dan Ilmu Komputer*, 6(2), 89-97.
- Putra, E., & Utami, M. (2024). Pengaruh Teknik Text Preprocessing Terhadap Akurasi Klasifikasi Teks Bahasa Indonesia. *Jurnal Sains dan Informatika*, 10(2), 112-120.
- Rakhman, A., & Hidayat, M. (2023). Pemanfaatan Neural Machine Translation untuk Penerjemahan Teks Kontekstual. *Jurnal Kecerdasan Buatan Indonesia*, 4(1), 15-23.
- Santoso, B., & Wibowo, A. (2022). *Pengantar Natural Language Processing: Teori dan Aplikasi Praktis*. Jakarta: Penerbit Informatika.

LAMPIRAN

1. Tautan GitHub Proyek

Seluruh kode sumber, dataset, model yang dilatih, serta berkas konfigurasi aplikasi web Streamlit untuk proyek penerjemah bahasa ini dapat diakses melalui tautan repositori GitHub resmi berikut:

https://github.com/violaansar090425-hash/UAS_NLP_Viola_penerjemah-bahasa-inggris.git